



中央财经大学  
Central University of Finance and Economics

# 计量经济学

中国财政发展协同创新中心

陈怡心

cyx@cufe.edu.cn



# 第4章 大样本OLS

陈怡心

中央财经大学中国财政发展协同创新中心

# 为何需要大样本理论？

- “大样本理论” (large sample theory), 也称 “渐近理论” (asymptotic theory), 研究当样本容量 $n$ 趋向无穷大时统计量的性质。
- 大样本理论已成为当代计量经济学的主流方法, 原因如下:
  - **(1) 小样本理论的假设过强。**

**首先, 小样本理论的严格外生性假设要求解释变量与所有的扰动项均正交(不相关)。**

在时间序列模型中, 这意味着解释变量与扰动项的过去、现在与未来值全部正交。

- **例** 考虑以下一阶自回归模型(first order autoregression, 简记AR(1)):

$$y_t = \rho y_{t-1} + \varepsilon_t \quad (t = 2, \dots, T)$$

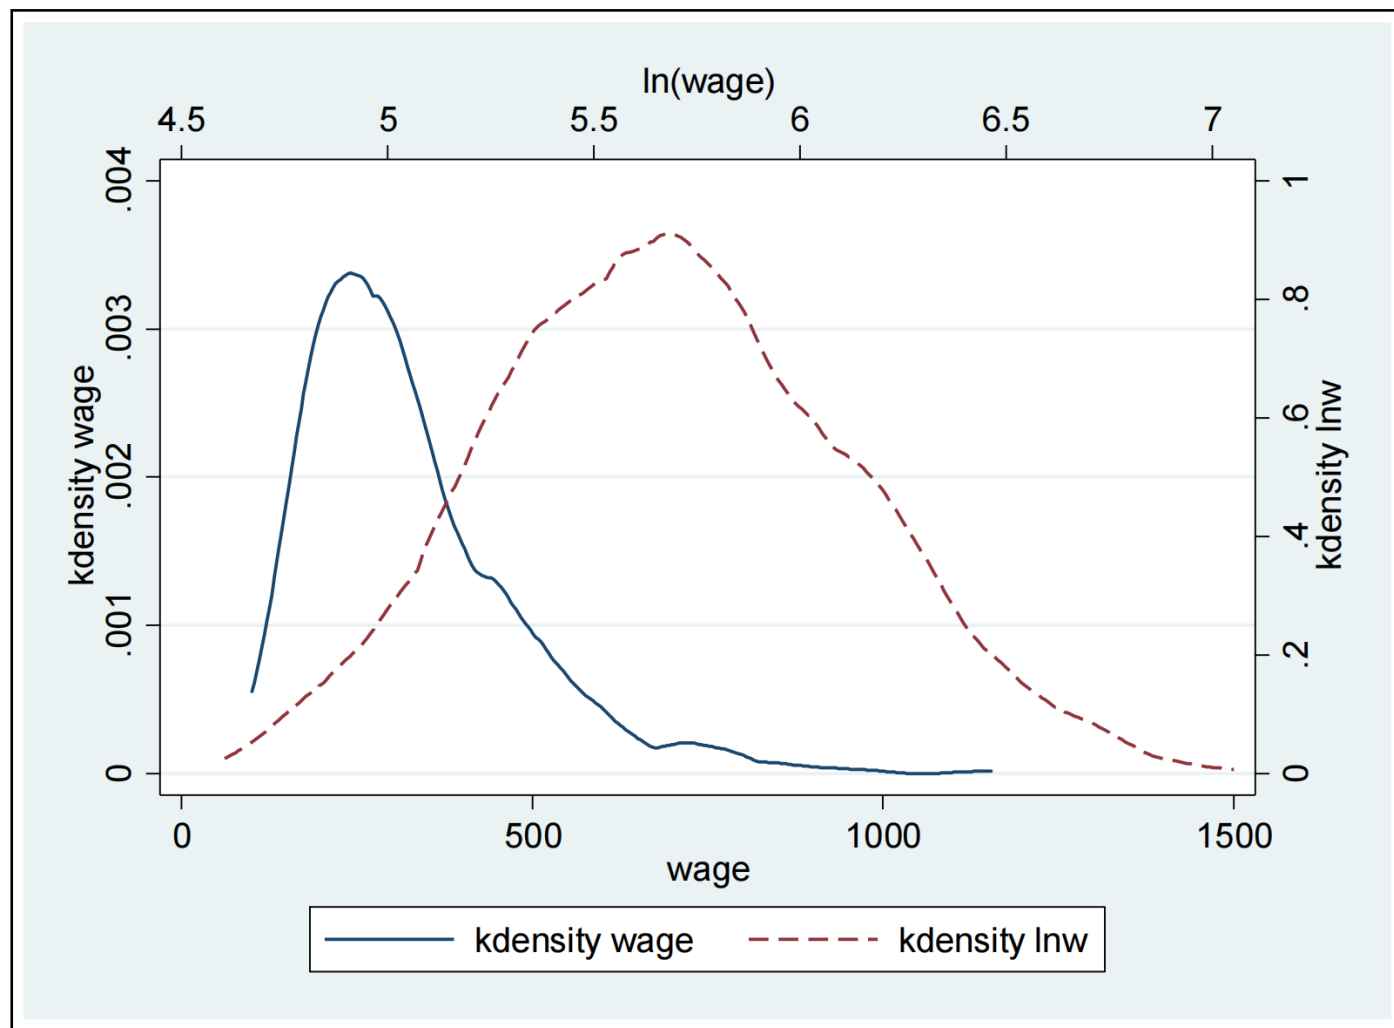
- 解释变量 $y_{t-1}$ 为被解释变量 $y_t$ 的一阶滞后; 且 $Cov(y_{t-1}, \varepsilon_t) = 0$ 。
- 严格外生性要求, 解释变量 $y_{t-1}$ 与所有 $\{\varepsilon_2, \dots, \varepsilon_T\}$ 均不相关。
- 这意味着,  $y_t$ 也不与 $\varepsilon_t$ 相关。但是 $\varepsilon_t$ 是 $y_t$ 的一部分, 故二者一定相关, 因为

$$Cov(y_t, \varepsilon_t) = Cov[\rho y_{t-1} + \varepsilon_t, \varepsilon_t] = \rho \underbrace{Cov(y_{t-1}, \varepsilon_t)}_{=0} + Var(\varepsilon_t) = Var(\varepsilon_t) > 0$$

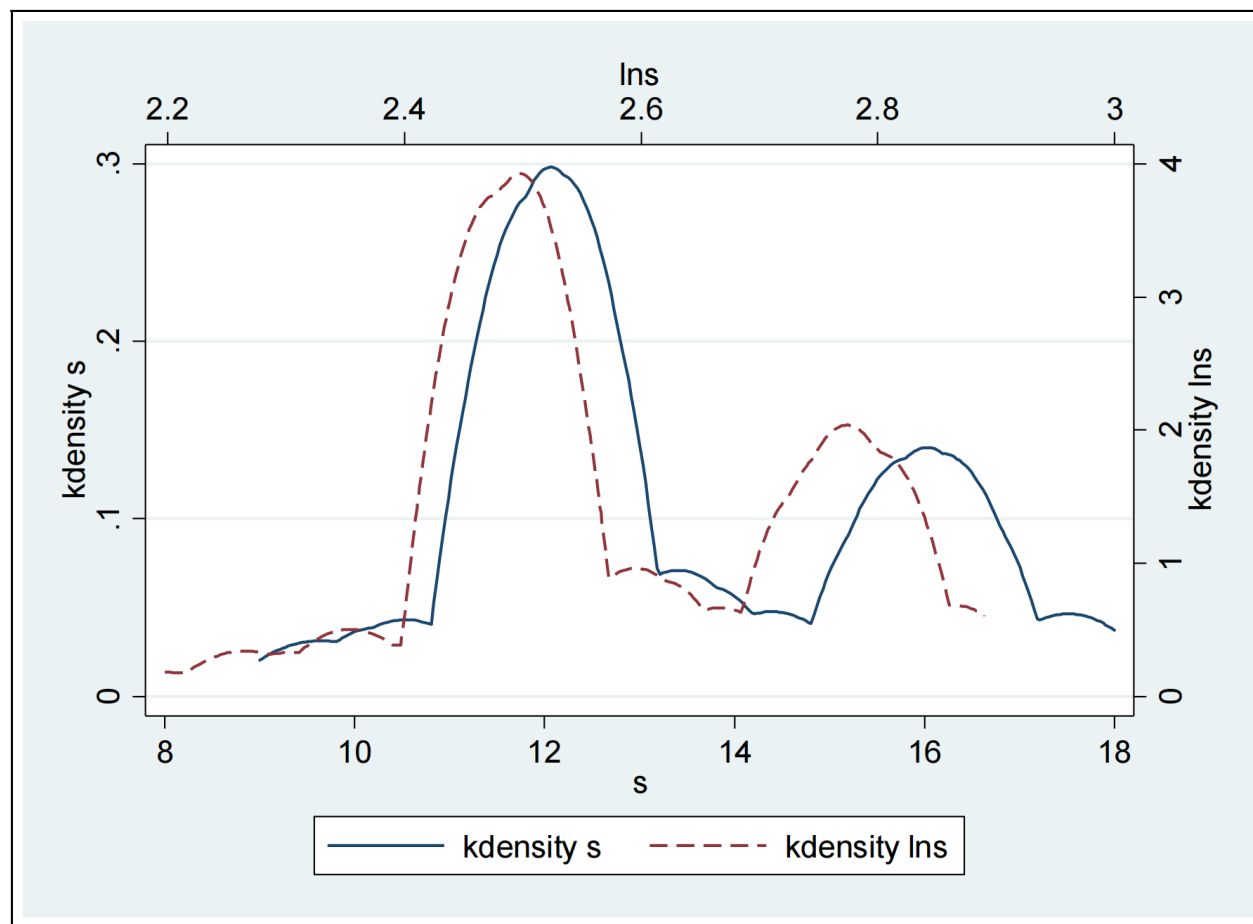
- 以被解释变量滞后值为解释变量的自回归模型, 必然违背严格外生性的假定。
- **大样本理论只要求解释变量与同期(同方程)的扰动项不相关。**

- **其次，小样本理论假定扰动项为正态分布，而大样本理论无此限制。**
- 在很多情况下，并无把握经济变量是否服从正态分布。
- 比如，正态分布为对称分布，但许多经济变量的分布并不对称，例如工资收入。
- 即使考虑比较对称的工资对数，由于正态变量的取值范围为 $(-\infty, +\infty)$ ，而工资对数一般为正数(假设工资大于 1)，也不相符。

- 工资的分布与正态分布相去甚远。
- 工资对数，在取值范围为 $(-\infty, +\infty)$ 上，也与正态分布不符。



- 被解释变量的分布可能为各种形状；有时即使取对数也不能使其接近正态分布。
- 教育年限的分布呈现“双峰”状，即多数人为中学或大学毕业。
- 这种双峰形状，即使取对数后，也难以改变。



- 无论教育年限还是其对数，都与“单峰”的正态分布相去甚远。
- 通过取对数使得变量的分布接近于正态并非万能。
- 对于小样本理论来说，为了进行统计推断(比如，推导t与F 统计量的分布)，须假设扰动项服从正态分布(故被解释变量也为正态)。
- 由于现实中的被解释变量可能服从各种分布(比如，变量婚否 为离散的两点分布)，故基于正态假设的小样本理论的适用范围受到很大限制。



- (2) 在小样本理论的框架下，须研究统计量的精确分布(exact distribution)，但常难以推导(即使在正态分布的假设之下)。

根据大样本理论，只要研究统计量的大样本分布，即当 $n \rightarrow \infty$ 时的渐近分布，相对容易推导(可使用大数定律与中心极限定理)。

- (3) 使用大样本理论的代价是要求样本容量较大，以便大数定律与中心极限定理可以起作用。

大样本理论对于样本容量的要求，一般认为至少 $n > 30$ ，最好在100以上。现代的数据集越来越大，经常成百上千。

在当代计量实践中，研究人员一般用大样本理论；小样本 OLS 已很少使用。

# 关于显著的N个tips：用大样本

- 一元线性回归下，t统计量简化为：

$$t = \frac{\hat{\beta}}{SE(\hat{\beta})} = \frac{\hat{\beta}}{\sqrt{\hat{\sigma}^2 / n \text{Var}(x)}}$$

- 如果你的结果不显著，因为什么呢？
  - $\hat{\beta}$  太小或  $SE(\hat{\beta})$  太大
- $\hat{\beta}$  太小的潜在原因：内生性（得到的  $\hat{\beta}$  有偏）/ $\beta$  原本就很小
- $SE(\hat{\beta})$  太大的潜在原因？
- 结果不显著，因为什么呢？
  - $\hat{\sigma}^2$  很大（扰动项方差很大）
  - $x$  的方差  $\text{Var}(x)$  很小（例如只有几个大学生）
  - 样本量  $n$  很小

# 为什么样本大了好？

- (1) 大数定律
  - 样本不够大，发现不了规律。 $\hat{\beta}$ 点估计值本身就不靠谱。
  - 样本小，standard error会大，导致统计显著性不过关。
  - 个别outlier的干扰会变小→影响对 $\sigma$ 的估计。
- (2) 有足够多的花样做异质性
- (3) 没有功劳，也有苦劳

# 数大便是美

## • 徐志摩 《志摩日记二则》

数大便是美。

碧绿的山坡前几千只绵羊，挨成一片的雪绒，是美；

一天的繁星，千万只闪亮的神眼，从无极的蓝空中下窥大地，是美；

泰山顶上的云海，巨万的云峰在晨光里静定着，是美；

大海万顷的波浪，戴著各式的白帽，在日光里动荡着，是美；

爱尔兰附近的那个羽毛岛上栖息着几千万的飞禽，夕阳西沉时只见一个羽化的大空，只是万鸟齐鸣的大声，是美.....

数大便是美。


数大了似乎按照著一种自然规律，自然也会有一种特别的排列，一种特别的节奏，一种特殊的式样，激动我们审美的本能，激发我们审美的情绪。

- 一些同学用分省数据、时序数据。
- 如果你的研究问题有更细的数据，就不要用粗的数据。分省VS分市VS微观
- 我们的幸运
  - 大国
  - 大数据时代
- 例外：Acemoglu, AER, The Colonial Origins of Comparative Development, 只有63个观测值！
  - 这很运气。稍微碰一下，显著性就没了。

# 随机收敛

- 1. 确定性序列的收敛

- **定义** 确定性序列 $\{a_n\}_{n=1}^{\infty} = \{a_1, a_2, a_3, \dots\}$ **收敛** (converge) 于常数 $a$ , 记为 $\lim_{n \rightarrow \infty} a_n \rightarrow a$  或  $a_n \rightarrow a$ , 如果对于任意小的正数 $\varepsilon > 0$ , 都存在 $N > 0$ , 只要 $n > N$ , 就有 $|a_n - a| < \varepsilon$ , 即在 $a_N$ 以后的序列 $\{a_{N+1}, a_{N+2}, \dots\}$ 均落入区间 $(a - \varepsilon, a + \varepsilon)$ 内



- **例** 假设 $a_n = 5 + \frac{1}{n}$ , 则 $\lim_{n \rightarrow \infty} a_n = \lim_{n \rightarrow \infty} (5 + \frac{1}{n}) = 5 + \lim_{n \rightarrow \infty} \frac{1}{n} = 5 + 0 = 5$

## • 2. 随机序列的收敛


• 考虑随机序列  $\{x_n\}_{n=1}^{\infty} = \{x_1, x_2, x_3, \dots\}$ , 即由随机变量构成的序列, 其中每个元素  $x_n$  都是随机变量, 下标  $n$  通常表示样本容量。

• **定义** 随机序列  $\{x_n\}_{n=1}^{\infty}$  **依概率收敛** (converge in probability) 于常数  $a$ ,

记为  $\text{plim}_{n \rightarrow \infty} x_n = a$ , 或  $x_n \xrightarrow{p} a$ , 如果对于任意  $\varepsilon > 0$ , 当  $n \rightarrow \infty$  时, 都

有  $\lim_{n \rightarrow \infty} P(|x_n - a| > \varepsilon) = 0$ 。

• 任意给定很小的正数  $\varepsilon > 0$ , 当  $n$  越来越大时, 随机变量  $x_n$  落在区间  $(a - \varepsilon, a + \varepsilon)$  之外的概率收敛于 0。



- 当 $n$ 变大时,  $x_n$ 远离常数 $a$ 的可能性越来越小, 变得几乎不可能。
- 由于已将随机事件( $|x_n - a| > \varepsilon$ )取概率, 故 $P(|x_n - a| > \varepsilon)$ 其实是确定性序列(为概率的具体取值, 已无不确定性), 而 $\lim_{n \rightarrow \infty} P(|x_n - a| > \varepsilon)$ 只是普通的微积分极限。



- **例** 假设 $x_n$ 服从如下两点分布：

$$x_n = \begin{cases} 0 & \text{取值概率 } 1-(1/n) \\ n & \text{取值概率 } 1/n \end{cases}$$

- 随着 $n \rightarrow \infty$ ， $x_n$ 的分布越来越集中于0，取值为n的可能性越来越小。故根据定义， $\lim_{n \rightarrow \infty} x_n = 0$ 。
- 利用随机变量依概率收敛于常数的概念，可定义随机变量之间的随机收敛，只要随机变量之差别依概率收敛于0。
- **定义** 随机序列 $\{x_n\}_{n=1}^{\infty}$  **依概率收敛**于随机变量 $x$ ，记为 $x_n \xrightarrow{p} x$ ，如果随机序列 $\{x_n - x\}_{n=1}^{\infty}$ 依概率收敛于0。

- 概率收敛( $\text{plim}_{n \rightarrow \infty}$ )的运算规则类似于微积分中极限( $\lim_{n \rightarrow \infty}$ )的运算。

- 比如, 假设 $g(\cdot)$ 为连续函数, 则

$$\lim_{n \rightarrow \infty} g(x_n) = g(\text{plim}_{n \rightarrow \infty} x_n)$$

- 概率极限 $\text{plim}_{n \rightarrow \infty}$ 与连续函数 $g(\cdot)$ 可交换运算次序。

- 当 $x_n$ 的分布越来越集中于 $x^* \equiv \text{plim}_{n \rightarrow \infty} x_n$ 附近时,  $g(x_n)$ 的分布自然也就越来越集中于 $g(x^*)$ 附近。

- 期望算子 $E(\cdot)$ 无此性质, 因为 $E(x^2) \neq [E(x)]^2$ 。这正是大样本理论的方便之处。

- **例** 如果  $\text{plim}_{n \rightarrow \infty} s^2 = \sigma^2$  (样本方差依概率收敛于总体方差), 则样本标准差  $s$  也依概率收敛于总体标准差  $\sigma$ , 因为

$$\text{plim}_{n \rightarrow \infty} s = \text{plim}_{n \rightarrow \infty} \sqrt{s^2} = \sqrt{\text{plim}_{n \rightarrow \infty} s^2} = \sqrt{\sigma^2} = \sigma$$

- 其中, “开根号” ( $\sqrt{\cdot}$ ) 是连续函数, 故可与求概率极限的运算交换次序。
- 对于**随机向量序列**(即序列中每个元素都是随机向量), 也可类似地定义依概率收敛, 只要定义其每个分量都依概率收敛即可。
- 比如, 随机向量序列  $\{x_n\}_{n=1}^{\infty} = \{x_1, x_2, x_3, \dots\}$  依概率收敛于随机向量  $x$ , 意味着  $x$  的每个分量都依概率收敛至  $x$  的相应分量, 记为  $\text{plim}_{n \rightarrow \infty} x_n = x$

- 3. 依均方收敛

- **定义** 如果随机序列 $\{x_n\}_{n=1}^{\infty}$ 的期望收敛于 $a$ , 即 $\lim_{n \rightarrow \infty} E(x_n) = a$ ; 而方差收敛于 0, 即 $\lim_{n \rightarrow \infty} Var(x_n) = 0$ , 则称 $\{x_n\}_{n=1}^{\infty}$  **依均方收敛** (converge in mean square)于常数 $a$ , 记为 $x_n \xrightarrow{ms} a$ 。

$$x_1, x_2, x_3, \cdots, x_n \cdots$$

$$E(x_1), E(x_2), E(x_3), \cdots, E(x_n), \cdots \rightarrow a$$

$$Var(x_1), Var(x_2), Var(x_3), \cdots, Var(x_n), \cdots \rightarrow 0$$

- 通过切比雪夫不等式，可以证明，依均方收敛意味着依概率收敛。
- 当 $x_n$ 的均值越来越趋于 $a$ ，而方差越来越小并趋于0时，就有 $\text{plim}_{n \rightarrow \infty} x_n = a$ ，即在极限处 $x_n$ 退化为常数 $a$ 。
- 证明均方收敛通常比证明概率收敛更容易，故可通过证明前者来证明后者，这也是依均方收敛概念的主要用途之一。
- 反之，依概率收敛并不意味着均方收敛。

- **例** 回到 $\{x_n\}$ 服从两点分布的例子，即 $x_n$ 取值为0的概率为 $1 - (1/n)$ ，而取值 $n$ 的概率为 $(1/n)$ 。虽然 $x_n$ 依概率收敛到0，但 $x_n$ 并不依均方收敛到0，因为此序列的期望恒等于1：


$$\lim_{n \rightarrow \infty} E(x_n) = \lim_{n \rightarrow \infty} \left[ 0 \cdot \left(1 - \frac{1}{n}\right) + n \cdot \frac{1}{n} \right] = 1 \neq 0$$

- 随着 $n \rightarrow \infty$ ，随机序列 $x_n$ 取值大于0的概率越来越小（为 $1/n$ ），但一旦取值为正数，则很大（等于 $n$ ），故此序列的期望始终为1。

- **4. 依分布收敛**


- **定义** 记随机序列 $\{x_n\}_{n=1}^{\infty}$ 与随机变量 $x$ 的累积分布函数分别为 $F_n(x)$ 与 $F(x)$ 。如果对于任意给定 $x$ , 都有 $\lim_{n \rightarrow \infty} F_n(x) = F(x)$ , 则称随机序列 $\{x_n\}_{n=1}^{\infty}$  **依分布收敛**(converge in distribution)于随机变量, 记为 $x_n \xrightarrow{d} x$ , 并称 $x$ 的分布为 $x_n$ 的**渐近分布**(asymptotic distribution)或**极限分布**(limiting distribution)。
- 当 $n \rightarrow \infty$ 时,  $x_n$ 的分布函数越来越像 $x$ 的分布函数。
- **例** 当t分布的自由度越来越大时, t分布依分布收敛于标准正态分布; 即当 $k \rightarrow \infty$ 时,  $t(k) \xrightarrow{d} N(0,1)$ 。

- 为了直观地显示依分布收敛的过程，在 Stata 中画  $N(0, 1)$ ， $t(1)$ 与 $t(5)$ 的累积分布函数





- 更直观地，可通过概率密度函数，来考察t分布依分布收敛于标准正态的过程



- 许多统计量的大样本分布均为正态分布，故引入如下概念。
- **定义** 如果  $x_n \xrightarrow{d} x$ ，且  $x$  服从正态分布，则称  $x_n$  为**渐近正态** (asymptotically normal)，即当  $n \rightarrow \infty$  时， $x_n$  的分布越来越像正态分布。
- 依分布收敛的运算也很方便。

假设  $x_n \xrightarrow{d} x$ ，而  $g(\cdot)$  为连续函数，则  $g(x_n)$  的渐近分布就是  $g(x)$ ，即  $g(x_n) \xrightarrow{d} g(x)$ 。

- 当  $x_n$  的分布越来越像  $x$  的分布时， $g(x_n)$  的分布自然也越来越多像  $g(x)$  的分布。这为大样本理论的推导提供了方便。

- **例** 假设  $x_n \xrightarrow{d} z$ , 其中  $z \sim N(0,1)$ , 则  $x_n^2 \xrightarrow{d} z^2$ , 其中  $z^2 \sim \chi(1)$ , 即  $x_n^2 \xrightarrow{d} \chi(1)$ , 因为平方是连续函数。
- 因此, 渐近标准正态的平方服从渐近  $\chi(1)$  的分布。
- “依概率收敛” 比 “依分布收敛” 更强, 前者是后者的充分条件; 但反之, 则不然。
- 如果  $x_n \xrightarrow{p} x$ , 则意味着  $(x_n - x) \xrightarrow{p} 0$ , 即在极限处  $x_n$  与  $x$  的具体取值无区别, 故二者的概率分布也必然相同, 所以  $x_n \xrightarrow{d} x$ 。
- 如果  $x_n \xrightarrow{d} x$ , 这只说明在极限处  $x_n$  与  $x$  的分布函数相同, 但  $x_n$  与  $x$  的实际取值仍可以很不相同 (比如,  $x_n$  与  $x$  相互独立)。

- **例** 假设 $x$ 与 $y$ 都为标准正态，且相互独立。考虑随机序列 $\{x_n = x + (1/n)\}_{n=1}^{\infty}$ 。
- 由于 $1/n \rightarrow 0$ ，故 $x_n$ 的渐近分布为标准正态，因此 $x_n \xrightarrow{d} y$ （ $y$ 也是标准正态）。
- 但 $x_n$ 却与 $y$ 相互独立， $x_n$ 的具体取值也与 $y$ 毫无关系，故 $x_n$ 并不依概率收敛于 $y$ 。
- 依分布收敛只是分布函数的收敛（随机变量之间可以毫无关系），而依概率收敛才是随机变量本身的收敛。
- 总之，“依均方收敛”  $\rightarrow$  “依概率收敛”  $\rightarrow$  “依分布收敛”。

# 大数定律与中心极限定理

- **1. 大数定律**(Law of Large Numbers)
- 假定 $\{x_n\}_{n=1}^{\infty}$ 为独立同分布的随机序列, 且 $E(x_1) = \mu$ ,  $Var(x_1) = \sigma^2$ 存在, 则样本均值 $\bar{x}_n \equiv \frac{1}{n} \sum_{i=1}^n x_i \xrightarrow{p} \mu$ 。
- 证明: 首先,  $E(\bar{x}_n) = \frac{1}{n} \sum_{i=1}^n E(x_i) = \frac{1}{n} \cdot n\mu = \mu$ , 故样本均值 $\bar{x}_n$ 的期望仍为 $\mu$ 。
- 其次,  $Var(\bar{x}_n) = Var(\frac{x_1 + \dots + x_n}{n}) = \frac{1}{n^2} (n\sigma^2) \rightarrow 0$ , 样本均值 $\bar{x}_n$ 的方差收敛到0。
- 因此,  $\bar{x}_n$ 依均方收敛于 $\mu$ 。
- 由此“依均方收敛”是“依概率收敛”的充分条件, 故 $\bar{x}_n \xrightarrow{p} \mu$ 。
- 当样本容量 $n$ 很大时, 样本均值趋于总体均值, 故名“大数定律”。

- **2. 中心极限定理**(Central Limit Theorem)

- 根据大数定律, 当 $n \rightarrow \infty$ 时, 样本均值 $\bar{x}_n$ 依概率收敛到总体均值 $\mu$ 。但一般情况下,  $\bar{x}_n$ 的具体分布很难推导。

- 中心极限定理告诉我们, 无论原序列 $\{x_n\}_{n=1}^{\infty}$ 服从什么分布, 当 $n \rightarrow \infty$ 时, 样本均值 $\bar{x}_n$ 的渐近分布都为正态分布。

- 只要样本容量 $n$ 足够大, 则 $\bar{x}_n$ 的真实分布将很接近于正态分布。

- **中心极限定理** 假定 $\{x_n\}_{n=1}^{\infty}$ 为独立同分布的随机序列, 且 $E(x_1) = \mu$ ,

$Var(x_1) = \sigma^2$ 存在, 则

$$\frac{\bar{x}_n - \mu}{\sqrt{\sigma^2/n}} \xrightarrow{d} N(0,1)$$

- 标准化之后的样本均值(即减去期望, 除以标准差)的渐近分布为标准正态。

- 直观上, 可视为  $\bar{x}_n \xrightarrow{d} N(\mu, \sigma^2/n)$ : 但不严格, 因为  $\bar{x}_n$  的方差  $\sigma^2/n \rightarrow 0$  (在极限处,  $\bar{x}_n$  的方差为 0, 故退化为常数  $\mu$ )。
- 将表达式两边同乘  $\sigma$ :

$$\sigma \left( \frac{\bar{x}_n - \mu}{\sqrt{\sigma^2/n}} \right) \xrightarrow{d} \sigma N(0,1)$$

因为乘以某常数  $\sigma$  为连续函数, 故根据依分布收敛的运算规则

$$y_n \xrightarrow{d} y \quad \Longrightarrow \quad \sigma y_n \xrightarrow{d} \sigma y$$

整理可得

$$\frac{\bar{x}_n - \mu}{\sqrt{1/n}} \xrightarrow{d} N(0, \sigma^2)$$

- 将  $\sqrt{1/n}$  放到分子上, 可得中心极限定理的等价表达式:

$$\sqrt{n}(\bar{x}_n - \mu) \xrightarrow{d} N(0, \sigma^2)$$

其中,  $\sqrt{n} \rightarrow \infty$ , 而根据大数定律,  $(\bar{x}_n - \mu) \xrightarrow{p} 0$ 。

故上式用  $\sqrt{n}(\bar{x}_n - \mu)$  (即“ $\infty \cdot 0$ ”型) 得到非退化的渐近正态分布  $N(0, \sigma^2)$ 。

而且,  $\bar{x}_n \xrightarrow{p} \mu$  的速度在数量级上与  $\sqrt{n}$  相当, 称为“root-n convergence”, 即  $(\bar{x}_n - \mu) \xrightarrow{p} 0$  的速度大约为

$$\frac{1}{\sqrt{1}}, \frac{1}{\sqrt{2}}, \frac{1}{\sqrt{3}}, \dots, \frac{1}{\sqrt{n}}, \dots$$

- 该式的好处是, 容易推广到多维的情形。
- **多维的中心极限定理**: 假定  $\{\mathbf{x}_n\}_{n=1}^{\infty}$  为独立同分布的随机向量序列, 且  $E(\mathbf{x}_1) = \boldsymbol{\mu}$ ,  $Var(\mathbf{x}_1) = \boldsymbol{\Sigma}$  存在, 则  $\sqrt{n}(\bar{\mathbf{x}}_n - \boldsymbol{\mu}) \xrightarrow{d} N(\mathbf{0}, \boldsymbol{\Sigma})$ 。




# 统计量的大样本性质

- 1. 一致估计量

- **定义** 考虑参数 $\beta$ 的估计量 $\hat{\beta}_n$ ，其中下标 $n$ 为容量（强调 $\hat{\beta}_n$ 对样本容量 $n$ 的依赖）。如果 $\text{plim}_{n \rightarrow \infty} \hat{\beta}_n = \beta$ ，则称 $\hat{\beta}_n$ 是参数 $\beta$ 的一致估计量(consistent estimator)。
- 在多维情况下，称估计量 $\hat{\beta}_n$ 是参数 $\beta$ 的一致估计量，如果 $\text{plim}_{n \rightarrow \infty} \hat{\beta}_n = \beta$ ，即 $\hat{\beta}_n$ 的各分量都是 $\beta$ 相应分量的一致估计。
- 一致性(consistency)意味着，当样本容量足够大时， $\hat{\beta}_n$ 依概率收敛到真实参数 $\beta$ 。
- 这是对估计量最基本，也是最重要的要求。

- 如果估计方法不一致，则意味着研究没有太大意义；因为无论样本容量多大，估计量也不会收敛到真实值。



- **2. 渐近正态分布与渐近方差**

- 定义 如果  $\sqrt{n}(\hat{\beta}_n - \beta) \xrightarrow{d} N(0, \sigma^2)$ , 则称  $\hat{\beta}_n$  为**渐近正态** (asymptotically normal), 称  $\sigma^2$  为其**渐近方差** (asymptotic variance), 记为  $Avar(\hat{\beta}_n)$ 。
- 可近似认为  $\hat{\beta}_n \xrightarrow{d} N(\beta, \sigma^2/n)$ , 但不严格 (方差  $\sigma^2/n$  趋于0, 故为退化的分布)。
- 在多维情况下, 如果  $\sqrt{n}(\hat{\beta}_n - \beta) \xrightarrow{d} N(\mathbf{0}, \Sigma)$ , 其中  $\Sigma$  为半正定矩阵, 则称  $\hat{\beta}_n$  为渐近正态分布, 而称  $\Sigma$  为  $\hat{\beta}_n$  的渐近协方差矩阵, 记为  $Avar(\hat{\beta}_n)$ 。


- **3. 渐近有效**

- 假设 $\hat{\beta}_n$ 与 $\tilde{\beta}_n$ 都是 $\beta$ 的渐近正态估计量。如果 $Avar(\hat{\beta}_n) \leq Avar(\tilde{\beta}_n)$ , 则称 $\hat{\beta}_n$ 比 $\tilde{\beta}_n$  **更为渐近有效**(asymptotically more efficient)。
- 在大样本下,  $\hat{\beta}_n$ 的方差小于 $\tilde{\beta}_n$ 的方差(在小样本下未必如此)。
- 在多维情况下, 假设 $\hat{\beta}_n$ 与 $\tilde{\beta}_n$ 都是 $\beta$ 的渐近正态估计量。如果 $[Avar(\tilde{\beta}_n) - Avar(\hat{\beta}_n)]$ 为半正定矩阵, 则称 $\hat{\beta}_n$ 比 $\tilde{\beta}_n$  **更为渐近有效**。

# 随机过程的性质

- 大数定律与中心极限定理假设随机序列为 iid，但对于大多数经济变量，此假定太强。
- 比如，今年的通货膨胀率通常依赖于去年的通货膨胀率，二者并非相互独立。
- 需要研究随机序列的性质，并将推广大数定律与中心极限定理。
- 随机序列  $\{x_n\}_{n=1}^{\infty}$  有个更好听的名称，叫“随机过程”(stochastic process)。
- 如下标为时间，则记为  $\{x_t\}_{t=1}^{\infty}$ ，也称“时间序列”(time series)。

- 1.严格平稳过程
- 考察中国 1978—2013 年的通货膨胀率，即 $\{\pi_{1978}, \pi_{1979}, \dots, \pi_{2013}\}$



- 假如每年的通货膨胀率作为随机变量都有不同的分布，如何估计  $E(\pi_{1978})$  与  $Var(\pi_{1978})$  呢？
- 每年通货膨胀率的样本容量仅为 1，且历史不能重演！
- 如果这 36 年的通货膨胀率分布都不变，则可将  $\bar{\pi} \equiv \frac{1}{36} \sum_{t=1978}^{2013} \pi_t$  作为  $E(\pi_t)$  的估计量。
- 通常要求随机过程  $\{x_n\}_{t=1}^{\infty}$  的概率分布不随时间推移而改变。
- 无论过去、现在还是未来去看此随机过程，它的概率分布性质都一样。

- 这种随机过程称为“严格平稳过程”，它要求随机过程的有限维分布不随时间推移而改变
- 比如，相同( $\forall t, s$ );
- $(x_1, x_4)$ 的分布与 $(x_2, x_5)$ 相同（二者均相隔3期）；
- $(x_1, x_2, x_3)$ 的分布与 $(x_5, x_6, x_7)$ 相同（二者均为连续3期）。



- **定义** 随机过程  $\{x_t\}_{t=1}^{\infty}$  是**严格平稳过程**(strictly stationary process), 简称平稳过程, 如果对任意 $m$ 个时期的时间集合 $\{t_1, t_2, \dots, t_m\}$ , 随机向量 $\{x_{t_1}, x_{t_2}, \dots, x_{t_m}\}$ 的联合分布等于随机向量 $\{x_{t_1+k}, x_{t_2+k}, \dots, x_{t_m+k}\}$ 的联合分布, 其中 $k$ 为任意整数。
- 将 $\{x_{t_1}, x_{t_2}, \dots, x_{t_m}\}$ 中每个变量的时间下标全部前移或后移 $k$ 期, 不会改变其分布。
- $\{x_{t_1}, x_{t_2}, \dots, x_{t_m}\}$ 的联合分布仅取决于 $\{t_1, t_2, \dots, t_m\}$ 各个时期之间的相对距离, 而不依赖于其绝对位置。

- **例** 如果随机过程 $\{x_t\}_{t=1}^{\infty}$ 为iid, 则 $\{x_t\}_{t=1}^{\infty}$ 是平稳过程, 且不存在序列相关。
- **例** 如果随机过程 $\{x_t\}_{t=1}^{\infty} = \{x_1, x_1, \dots, x_1\}$  (即 $x_t \equiv x_1$ ) , 则 $\{x_t\}_{t=1}^{\infty}$ 是平稳过程, 且存在最强的序列相关。
- **例** 考虑以下一阶自回归过程(AR(1)),

$$y_t = \rho y_{t-1} + \varepsilon_t \quad (t = 1, \dots, T)$$

其中,  $\{\varepsilon_t\}$ 为独立同分布, 且 $Cov(y_{t-1}, \varepsilon_t) = 0$ 。

- **命题** 如果 $\rho = 1$ , 则 $y_t = y_{t-1} + \varepsilon_t$ 。因此,  $y_1 = y_0 + \varepsilon_1$ , 而 $y_2 = y_1 + \varepsilon_2 = y_0 + \varepsilon_1 + \varepsilon_2$ , 以此类推可知

$$y_t = y_0 + \varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_t$$

给定初始值 $y_0$ , 当 $t \rightarrow \infty$ 时,

$$Var(y_t) = Var(\varepsilon_1) + Var(\varepsilon_2) + \dots + Var(\varepsilon_t) = t\sigma_{\varepsilon}^2 \rightarrow \infty,$$

其中 $\sigma_{\varepsilon}^2 \equiv Var(\varepsilon_t)$ , 即方差越来越大, 以至无穷。

- 故 $\{y_t\}$ 不是平稳过程(平稳过程要求同分布, 故方差不变)。

- 由于 $y_t$ 只是在 $y_{t-1}$ 的基础上, 加上随机扰动项 $\varepsilon_t$ , 故当 $\rho = 1$ 时, 称 $\{y_t\}$ 为“随机游走”(random walk)。
- 如果 $|\rho| < 1$ , 则 $Var(y_t)$ 会收敛到常数。对方程两边同时取方差, 可得

$$Var(y_t) = \rho^2 Var(y_{t-1}) + \sigma_\varepsilon^2$$

- 记 $z_t \equiv Var(y_t)$ ,  $z_{t-1} = Var(y_{t-1})$ , 则上式可写为


$$z_t = \rho^2 z_{t-1} + \sigma_\varepsilon^2$$

- 这是确定性的一阶线性差分方程, 因为 $z_t \equiv Var(y_t)$ 为非随机。
- 由于 $\rho^2 < 1$ , 故 $Var(y_t)$ 将收敛到一个稳定值。
- 令 $z_t = z_{t-1}$ , 可求解此收敛的稳定值 $z^*$ :

$$z^* = \rho^2 z^* + \sigma_\varepsilon^2$$

- 将上式整理后可得,  $z^* = \frac{\sigma_\varepsilon^2}{1-\rho^2}$ 。

- 如果忽略序列 $\{y_t\}$ 的前面几项, 可将 $\{y_t\}$ 的方差视为常数。
- 进一步可证明,  $\{y_t\}_{t=0}^\infty$ 是严格平稳过程。



- 有时仅关心随机过程的期望、方差及协方差是否稳定，而不要求整个分布都稳定，故引入以下“弱平稳过程”的概念。
- **定义** 随机过程 $\{x_t\}_{t=1}^{\infty}$ 是**弱平稳过程**(weakly stationary process)或**协方差平稳过程**(covariance stationary process)，如果 $E(x_t)$ 不依赖于 $t$ ，而且 $Cov(x_t, x_{t+k})$ 仅依赖于 $k$ （即 $x_t$ 与 $x_{t+k}$ 在时间上的相对距离）而不依赖于其绝对位置 $t$ 。
- 对于弱平稳过程，由于 $E(x_t)$ 不依赖于 $t$ ，故其期望为常数。
- 由于 $Cov(x_t, x_{t+k})$ 仅依赖于 $k$ ，如果 $k = 0$ ，则 $Cov(x_t, x_t) = Var(x_t)$ 也不依赖于 $t$ ，故弱平稳过程的方差也是常数。
- 严格平稳过程是弱平稳过程的充分条件；但反之则不然。
- 弱平稳过程只要求二阶矩平稳（即期望、方差、协方差等不随时间而变），而概率分布还可能依赖于更高阶的矩。

- **定义** 对于弱平稳过程 $\{x_t\}_{t=1}^{\infty}$ , 如果对于 $\forall t$ , 都有 $E(x_t) = 0$ , 而且 $Cov(x_t, x_{t+k}) = 0 (\forall k \neq 0)$ , 则称为**白噪声过程**(white noise process)。
- 白噪声过程不一定独立同分布, 也不一定是严格平稳过程。
- “白噪声”是性质比较好的“噪声”, 即该噪声的期望值为 0, 而不同期之间的噪声互不相关。
- 推广到多维: 对于随机向量过程 $\{\mathbf{x}_t\}_{t=1}^{\infty}$ , 可以类似地定义平稳过程或弱平稳过程 (只要将上述定义中的 $x$ 替换为 $\mathbf{x}$ 即可)。
- 对于随机向量过程 $\{\mathbf{x}_t\}_{t=1}^{\infty}$ 为 (弱) 平稳过程, 则其每个分量都是 (弱) 平稳过程; 反之, 则不然。

- 2.渐近独立性
- “严格平稳过程” (相当于“同分布”假定)还不足以应用大数定律或中心极限定理，因为它们都要求独立同分布(iid)。
- 但“相互独立”的假定对于大多数经济变量过强。
- 比如，今年的通胀率显然与去年的通胀率相关。
- 但今年的通胀率与 100 年前的通胀率或许可近似地视为相互独立，称为**渐近独立**(ergodic，也称**遍历性**)，或**弱相依**(weakly dependent)。
- 渐近独立意味着，只要两个随机变量相距足够远，可近似认为它们相互独立。
- **例** 相互独立的随机序列是渐近独立的。

- **例** AR(1)是否渐近独立？

考虑以下一阶自回归模型：

$$y_t = \rho y_{t-1} + \varepsilon_t$$

其中， $|\rho| < 1$ ，而 $\varepsilon_t$ 为白噪声。

- 计算其各阶“自协方差” (autocovariance)。

- 当时间间隔为 1 期时，一阶自协方差为

- $$\text{Cov}(y_t, y_{t-1}) = \text{Cov}(\rho y_{t-1} + \varepsilon_t, y_{t-1}) = \rho \sigma_y^2 + \underbrace{\text{Cov}(\varepsilon_t, y_{t-1})}_{=0} = \rho \sigma_y^2$$

- 其中， $\sigma_y^2$ 为 $y$ 的方差；而

$$\text{Cov}(\varepsilon_t, y_{t-1}) = \text{Cov}(\varepsilon_t, \rho y_{t-2} + \varepsilon_{t-1}) = \text{Cov}(\varepsilon_t, \varepsilon_{t-1}) = 0$$

因为 $\varepsilon_t$ 为白噪声。



- 当时间间隔为2期时，原方程可写为

$$y_t = \rho y_{t-1} + \varepsilon_t = \rho(\rho y_{t-2} + \varepsilon_{t-1}) + \rho^2 = \rho^2 y_{t-2} + \rho \varepsilon_{t-1} + \varepsilon_t$$

- 因此，二阶自协方差为

- $Cov(y_t, y_{t-2}) = Cov(\rho^2 y_{t-2} + \rho \varepsilon_{t-1} + \varepsilon_t, y_{t-2}) = \rho^2 \sigma_y^2$

- 以此类推，当时间间隔为 $j$ 期时，

$$Cov(y_t, y_{t-j}) = \rho^j \sigma_y^2$$

- 由于 $|\rho| < 1$ ，故当上式 $j \rightarrow \infty$ 时， $Cov(y_t, y_{t-j}) \rightarrow 0$ 。
- 相距越远，则序列 $\{y_t\}$ 的自协方差越小，且在极限处变为0(不相关)，故此AR(1)模型为渐近独立的过程。

- **渐近独立定理**(Ergodic Theorem) 假设 $\{x_i\}_{i=1}^{\infty}$ 为渐近独立的严格平稳过程, 且 $E(x_i) = \mu$ 存在, 则 $\bar{x}_n \equiv \frac{1}{n} \sum_{i=1}^n x_i \xrightarrow{p} \mu$ , 即样本均值 $\bar{x}_n$ 是总体均值 $E(x_i)$ 的一致估计。
- 渐近独立定理是对大数定律的重要推广, 更适用于经济数据。
- 大数定律要求每个 $x_i$ 相互独立, 而渐近独立定理允许 $\{x_i\}_{i=1}^{\infty}$ 存在“序列相关”(serial correlation), 只要此相关关系在极限处消失即可。
- 大数定律要求每个 $x_i$ 的分布相同, 而渐近独立定理要求 $\{x_i\}_{i=1}^{\infty}$ 为严格平稳过程, 故也是同分布的。
- 类似地, 可将中心极限定理作相应的推广; 即在一定条件下, 中心极限定理也适用于渐近独立的平稳过程。

- **命题** 如果 $\{x_i\}_{i=1}^{\infty}$ 为渐近独立的严格平稳过程，则对于任何连续函数 $f(\cdot)$ ， $\{y_i \equiv f(x_i)\}_{i=1}^{\infty}$ 也是渐近独立的严格平稳过程。
- 根据此命题，则渐近独立定理意味着，渐近独立平稳过程 $\{x_i\}_{i=1}^{\infty}$ 的任何“总体矩” (population moment)  $E[f(x_i)]$ ，都可以由其对应的“样本矩” (sample moment)  $\frac{1}{n} \sum_{i=1}^n f(x_i)$ 来一致地估计。

- **例** 对于渐近独立的平稳过程  $\{x_i\}_{i=1}^{\infty}$  样本方差  $s^2 \equiv \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$  , 是总体方差  $Var(x) = E[x - E(x)]^2$  的一致估计。
- **例** 样本协方差  $s_{xy} \equiv \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$  , 为总体协方差  $Cov(x, y) \equiv E[(x - E(x))(y - E(y))]$  的一致估计。

# 大样本OLS的假定

- **假定1** 线性假定

$$y_i = \beta_1 + \beta_2 x_{i2} + \cdots + \beta_K x_{iK} + \varepsilon_i \quad (i = 1, \cdots, n)$$

此假定与小样本OLS完全相同。

- **假定2**  $(K + 1)$ 维随机过程 $\{y_i, x_{i1}, \cdots, x_{iK}\}$ 为渐近独立的平稳过程 (ergodic stationarity), 故适用大数定律与中心极限定理。
- **例** 如果样本为随机样本, 则 $\{y_i, x_{i1}, \cdots, x_{iK}\}$ 独立同分布, 故是渐近独立的平稳过程。

- **假定3** 前定解释变量(predetermined regressors)

所有解释变量均为“前定”(predetermined), 也称“同期外生”(contemporaneously exogenous), 即它们与同期(同方程)的扰动项正交, 即 $E(x_{ik}\varepsilon_i) = 0, \forall i, k$ 。

由于 $E(x_{ik}\varepsilon_i) = 0$ , 故 $x_{ik}$ 与 $\varepsilon_i$ 不相关, 仿佛在 $\varepsilon_i$ 产生之前,  $x_{ik}$ 已经确定, 故名“前定解释变量”。

此假定比严格外生性假定更弱, 因为后者要求扰动项与过去、现在及未来的解释变量都不相关(对于时间序列数据而言), 而前定变量仅要求与同期的扰动项不相关。

- **假定4** 秩条件(rank condition)

数据矩阵 $X$  满列秩, 即 $X$  中没有多余(可由其他变量线性表出)的解释变量, 故不存在严格多重共线性。

- 大样本理论的假定 1 与 4 与小样本理论相同, 而假定 2 与3 则比小样本理论更为放松。
- 大样本 OLS 无须假设“严格外生性”与“正态随机扰动项”, 具有更大的适用性。

# OLS的大样本性质

- 在假定1-4之下, OLS 估计量 $\hat{\beta}$ 具有以下良好的大样本性质。
- (1)  **$\hat{\beta}$ 为一致估计量, 即**
$$\text{plim}_{n \rightarrow \infty} \hat{\beta} = \beta$$

以一元回归为例。考虑以下模型:

$$y_i = \alpha + \beta x_i + \varepsilon_i \quad (i = 1, \dots, n)$$

$\beta$ 的OLS估计量为

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$



- 此模型的离差形式为

$$(y_i - \bar{y}) = \beta(x_i - \bar{x}) + (\varepsilon_i - \bar{\varepsilon})$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i, \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{\varepsilon} = \frac{1}{n} \sum_{i=1}^n \varepsilon_i$$

- 代入 $\hat{\beta}$ 的表达式可得

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x}) [\beta(x_i - \bar{x}) + (\varepsilon_i - \bar{\varepsilon})]}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$= \frac{\beta \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (x_i - \bar{x})(\varepsilon_i - \bar{\varepsilon})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$= \beta + \frac{\sum_{i=1}^n (x_i - \bar{x})(\varepsilon_i - \bar{\varepsilon})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$= \beta + \frac{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(\varepsilon_i - \bar{\varepsilon})}{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \xrightarrow{p} \beta + \underbrace{\frac{\text{Cov}(x_i, \varepsilon_i)}{\text{Var}(x_i)}}_{=0} = \beta$$

其中,  $\text{Cov}(x_i, \varepsilon_i) = 0$

- 前定解释变量，或扰动项与解释变量同期不相关，是保证 OLS 一致的最重要条件。

- 反之，如果  $Cov(x_i, \varepsilon_i) \neq 0$ ，则  $\text{plim}_{n \rightarrow \infty} \hat{\beta} = \beta + \frac{Cov(x_i, \varepsilon_i)}{Var(x_i)} \neq \beta$


- 如果  $Cov(x_i, \varepsilon_i) > 0$ ，则  $\text{plim}_{n \rightarrow \infty} \hat{\beta} > \beta$

比如，考察教育投资的回报率， $x_i$  为教育年限，而  $\varepsilon_i$  为被遗漏的个人能力。 $x_i$  与  $\varepsilon_i$  正相关(能力高者通常上学更久)，故 OLS 估计量将高估教育投资的回报率。

- 如果  $Cov(x_i, \varepsilon_i) < 0$ ，则  $\text{plim}_{n \rightarrow \infty} \hat{\beta} < \beta$

比如，考察上医院对健康的作用， $x_i$  为是否上医院，而  $\varepsilon_i$  为个人原来的健康状况(被遗漏)。 $x_i$  与  $\varepsilon_i$  负相关(通常只有健康不佳者才上医院)，故 OLS 估计量将低估上医院对健康的正面作用(去医院者的健康往往不如未去医院者)。

- 通过图示考察  $Cov(x_i, \varepsilon_i) \neq 0$  的后果
- 真实(总体)回归线为  $\alpha + \beta x_i$
- 样本回归线为  $\hat{\alpha} + \hat{\beta} x_i$
- 假设  $Cov(x_i, \varepsilon_i) > 0$ ,  $x_i$  与  $\varepsilon_i$  正相关
- 当  $x_i$  较小时,  $\varepsilon_i$  也倾向于较小
- 当  $x_i$  较大时,  $\varepsilon_i$  也倾向于较大
- 反之, 如果  $Cov(x_i, \varepsilon_i) < 0$ , 则  $\hat{\beta}$  将低估  $\beta$ 。
- 增大样本容量 ( $n \rightarrow \infty$ ) 也不能使偏差(bias)消失。



- 在计量经济学中，如果解释变量与扰动项相关，即  $Cov(x_i, \varepsilon_i) \neq 0$ ，则称此解释变量为“内生解释变量” (endogenous regressor)，简称“内生变量”。反之，则为“外生变量”(exogenous variable)。
- 由于内生变量的存在，致使 OLS 回归出现偏差，统称为“内生性偏差”(endogeneity bias)，或简称“内生性”。
- 在什么情况下可能出现内生性偏差？
- 如果存在**遗漏变量、双向因果关系、或解释变量测量误差** (measurement errors)，常会出现解释变量与扰动项同期相关的情形，导致 OLS 不一致。

- (2)  $\hat{\beta}$ 服从渐近正态分布, 即 $\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(\mathbf{0}, Avar(\hat{\beta}))$

其中,  $Avar(\hat{\beta})$ 为 $\hat{\beta}$ 的渐近协方差矩阵。

$\hat{\beta}$ 之所以服从渐近正态, 因为在一定条件下, 中心极限定理适用于渐近独立的平稳过程。

- (3) 由于大样本理论一般不假设球形扰动项，故渐近协方差矩阵  $Avar(\hat{\beta})$  的表达式更为复杂。
- OLS 估计量  $\hat{\beta}$  的协方差矩阵可写为：

$$\text{Var}(\hat{\beta} | X) = (X'X)^{-1} X' \text{Var}(\varepsilon | X) X (X'X)^{-1}$$

其中， $\text{Var}(\varepsilon|X)$  为扰动项的协方差矩阵。

- 如果存在球形扰动项(同方差、无自相关)，则  $\text{Var}(\varepsilon|X) = \sigma^2 I_n$
- 上式简化为

$$\text{Var}(\hat{\beta} | X) = (X'X)^{-1} X' (\sigma^2 I_n) X (X'X)^{-1} = \sigma^2 (X'X)^{-1}$$

- 对于横截面数据, 经常存在异方差, 但无自相关(比如, 各截面单位之间相互独立)。
- 考虑存在条件异方差, 但无自相关的情形。
- 扰动项的协方差矩阵可写为

$$\text{Var}(\boldsymbol{\varepsilon} \mid \boldsymbol{X}) = \begin{pmatrix} \sigma_1^2 & & 0 \\ & \ddots & \\ 0 & & \sigma_n^2 \end{pmatrix}$$

- 其中,  $\sigma_1^2, \dots, \sigma_n^2$  不全相等。

- 如何估计上式的 $\{\sigma_1^2, \dots, \sigma_n^2\}$ ?
- 其中,  $\sigma_1^2 = \text{Var}(\varepsilon_1) = E(\varepsilon_1^2) - [E(\varepsilon_1)]^2 = E(\varepsilon_1^2)$
- 以 OLS 残差平方 $\{e_1^2, \dots, e_n^2\}$ 替代上式的 $\{\sigma_1^2, \dots, \sigma_n^2\}$ , 得到扰动项协方差矩阵的估计量:

$$\widehat{\text{Var}(\boldsymbol{\varepsilon} | \mathbf{X})} = \frac{n}{n-K} \begin{pmatrix} e_1^2 & & 0 \\ & \ddots & \\ 0 & & e_n^2 \end{pmatrix}$$

- 其中,  $\frac{n}{n-K}$ 为自由度的调整 (在大样本下无差别)。



- 将上式代入 $\widehat{\text{Var}}(\hat{\beta} | X)$ 的表达式，可得如下方差估计量

$$\widehat{\text{Var}}(\hat{\beta} | X) = (X'X)^{-1} X' \widehat{\text{Var}}(\varepsilon | X) X (X'X)^{-1}$$

- 考虑 $\sqrt{n}\hat{\beta}$ 的方差估计量，即 $\hat{\beta}$ 的**渐近方差估计量**：

$$\widehat{\text{Avar}}(\hat{\beta} | X) = n (X'X)^{-1} X' \widehat{\text{Var}}(\varepsilon | X) X (X'X)^{-1}$$

- 上式为 $\hat{\beta}$ 渐近协方差矩阵的一致估计量，即

$$\widehat{\text{Avar}}(\hat{\beta} | X) \xrightarrow{p} \text{Avar}(\hat{\beta} | X)$$

- 由于表达式在推导过程中并未假设“条件同方差”，故在“条件异方差”情况下也成立，称为“异方差稳健的标准误” (heteroskedasticity-consistent standard errors)，简称“稳健标准误” (robust standard errors)。

- 在形式上，稳健标准误也是夹心估计量。
- 稳健标准误的思想最早由 Eicker(1967)与 Huber(1967)提出，并由 White(1980) 严格证明，故也称 White' s standard errors , Huber-White standard errors, 或 Eicker-Huber-White standard errors。
- 稳健标准误的表达式虽较复杂，但对于计算机，其计算成本可以忽略(无须人为记忆)。
- 通过使用迭代期望定律可以证明，在条件同方差的假定下，稳健标准误还原为普通(非稳健)标准误。

- 考虑同方差的极端情形, 即  $e_1^2 = e_2^2 = \dots = e_n^2$  (所有残差的绝对值都相等, 但符号可以相反), 则

$$\widehat{\text{Var}}(\boldsymbol{\varepsilon} | \mathbf{X}) = \frac{n}{n-K} \begin{pmatrix} e_1^2 & & 0 \\ & \ddots & \\ 0 & & e_n^2 \end{pmatrix} = \frac{ne_i^2}{n-K} \mathbf{I}_n = \frac{\sum_{i=1}^n e_i^2}{\underbrace{n-K}_{=s^2}} \mathbf{I}_n = s^2 \mathbf{I}_n$$

- 稳健的协方差矩阵简化为同方差情况下的普通(非稳健)协方差矩阵:

$$\begin{aligned} \widehat{\text{Var}}(\hat{\boldsymbol{\beta}} | \mathbf{X}) &= (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' \widehat{\text{Var}}(\boldsymbol{\varepsilon} | \mathbf{X}) \mathbf{X} (\mathbf{X}'\mathbf{X})^{-1} \\ &= (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' (s^2 \mathbf{I}_n) \mathbf{X} (\mathbf{X}'\mathbf{X})^{-1} = s^2 (\mathbf{X}'\mathbf{X})^{-1} \end{aligned}$$

# 大样本统计推断

- 对于渐近独立的平稳过程，如果样本容量足够大，则 OLS 估计量  $\hat{\beta}$  的渐近正态分布是对其真实分布的较好近似，可使用其渐近分布进行大样本假设检验与区间估计。
- 大样本统计推断(large sample inference)的步骤与小样本 OLS 基本相同。

- **1. 检验单个系数:**  $H_0: \beta_k = c$
- 考虑检验  $H_0: \beta_k = c$ , 其中  $c$  为已知常数。
- 根据大样本理论, OLS 估计量  $\hat{\boldsymbol{\beta}}$  服从渐近正态分布, 即  $\sqrt{n}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \xrightarrow{d} N(\mathbf{0}, Avar(\hat{\boldsymbol{\beta}}))$ , 其中  $Avar(\hat{\boldsymbol{\beta}})$  为渐近协方差矩阵。
- 具体到  $\hat{\boldsymbol{\beta}}$  的第  $k$  个元素  $\hat{\beta}_k$ , 则有
 
$$\sqrt{n}(\hat{\beta}_k - \beta_k) \xrightarrow{d} N(0, Avar(\hat{\beta}_k))$$
- $Avar(\hat{\beta}_k)$  为  $\hat{\beta}_k$  的渐近方差, 即渐近方差矩阵  $Avar(\hat{\boldsymbol{\beta}})$  主对角线上的第  $k$  个元素。

- 在原假设 $H_0$ 成立的情况下,  $\beta_k = c$ , 故表达式可写为

$$\sqrt{n}(\hat{\beta}_k - c) \xrightarrow{d} N(0, Avar(\hat{\beta}_k))$$

- 记 $\widehat{Avar}(\hat{\beta}_k)$ 为渐近方差矩阵估计量 $\widehat{Avar}(\hat{\beta})$ 主对角线上的第 $k$ 个元素, 则 $\widehat{Avar}(\hat{\beta}_k)$ 是 $Avar(\hat{\beta}_k)$ 的一致估计量。
- 定义 $t$ 统计量为

$$t_k \equiv \frac{\sqrt{n}(\hat{\beta}_k - c)}{\sqrt{\widehat{Avar}(\hat{\beta}_k)}} = \frac{\hat{\beta}_k - c}{\sqrt{\frac{1}{n} \widehat{Avar}(\hat{\beta}_k)}} \equiv \frac{\hat{\beta}_k - c}{SE^*(b_k)} \xrightarrow{d} N(0, 1)$$

- $SE^*(\hat{\beta}_k) \equiv \sqrt{\frac{1}{n} \widehat{Avar}(\hat{\beta}_k)}$ 即为异方差稳健的标准误。
- 统计量 $t_k$ 称为“稳健 $t$ 比值”(robust t ratio), 服从渐近标准正态分布, 而不是 $t$ 分布。

- 对于双边检验(即 $H_1: \beta_k \neq c$ ), 则 $|t_k|$ 越大, 越倾向于拒绝 $H_0$ 。
- 比如, 对于 5%的显著性水平, 如果 $|t_k|$ 大于临界值1.96, 则可拒绝 $H_0$ 。
- 也可以通过 $p$ 值进行检验, 方法与小样本理论相同。

- 2. 检验线性假设:  $H_0: R\beta = r$
- 考虑检验 $m$ 个线性假设是否同时成立:

$$H_0: \underbrace{R}_{m \times K} \underbrace{\beta}_{K \times 1} = \underbrace{r}_{m \times 1}$$

- 其中,  $r$ 为 $m$ 维列向量( $m < K$ ),  $R$ 为 $m \times K$ 矩阵。
- $rank(R) = m$ , 即 $R$ 满行秩, 没有多余或自相矛盾的行或方程。
- 对于原假设 $H_0: R\beta = r$ , 根据沃尔德检验原理, 可考察 $(R\hat{\beta} - r)$ 的大小, 譬如其二次型 $(R\hat{\beta} - r)'(R\hat{\beta} - r)$ 。



- 在 $H_0$ 成立的情况下，可证明统计量

$$W \equiv n(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})' [\widehat{\mathbf{RAvar}(\hat{\boldsymbol{\beta}})\mathbf{R}'}]^{-1} (\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}) \xrightarrow{d} \chi^2(m)$$

- $\mathbf{RAvar}(\hat{\boldsymbol{\beta}})\mathbf{R}'$ 为 $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})$ 的渐近方差矩阵(使用夹心估计量公式)。
- 如果统计量 $W$ 大于 $\chi^2(m)$ 的临界值，则拒绝原假设。
- 虽然统计量 $W$ 服从 $\chi^2$ 分布，而非小样本的 $F$ 分布，但 $\chi^2$ 分布与 $F$ 分布在大样本情况下是等价的。
- 即使在大样本下使用稳健标准误进行假设检验，Stata 也依然汇报 $F$ 统计量及其 p值。

- **命题** 假设统计量  $F \sim F(m, n)$  分布, 则当  $n \rightarrow \infty$  时,  $mF \xrightarrow{d} \chi^2(m)$ 。
- **证明:** 因为  $F \sim F(m, n)$ , 故可写为  $F = \frac{\chi^2(m)/m}{\chi^2(n)/n}$ , 其中分子与分母相互独立。
- 根据  $\chi^2$  分布的性质,  $\chi^2$  分布的期望等于自由度, 而方差等于自由度的两倍; 即  $E[\chi^2(n)] = n$ , 且  $Var[\chi^2(n)] = 2n$ 。
- 分母的期望为  $E[\chi^2(n)/n] = n/n = 1$ , 而方差为  $Var[\chi^2(n)/n] = 2n/n^2 = 2/n \rightarrow 0$  (当  $n \rightarrow \infty$  时)。
- 分母依均方收敛于 1, 故依概率收敛于 1 (前者是后者的充分条件), 即  $\chi^2(n)/n \xrightarrow{p} 1$ 。
- $F$  统计量的性质仅由分子  $\chi^2(m)/m$  决定, 故  $F \xrightarrow{d} \chi^2(m)/m$ 。
- 因此, 在大样本下,  $mF \xrightarrow{d} \chi^2(m)$ 。

# 一元回归实例

. reg lnw s							
	Source	SS	df	MS	Number of obs	=	758
ESS	Model	35.2039946	1	35.2039946	F(1, 756)	=	255.70
RSS	Residual	104.082155	756	.137674809	Prob > F	=	0.0000
					R-squared	=	0.2527
					Adj R-squared	=	0.2518
TSS	Total	139.28615	757	.183997556	Root MSE	=	.37105
		回归系数	标准误				
被解释变量	lnw	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
解释变量	s	.0966245	.0060425	15.99	0.000	.0847624	.1084866
	_cons	4.391486	.0821136	53.48	0.000	4.230288	4.552684
	常数项						

$$\hat{\alpha} = 4.391, \hat{\beta} = 0.097$$

$$\widehat{\ln w} = 4.391 + 0.097s$$

教育的投资回报率为9.7%，  
每增加一年教育，平均可提高收入9.7%

# 多元回归实例

```
. reg lnw s expr tenure smsa rns
```

	Source	SS	df	MS	Number of obs	=	758
ESS	Model	49.0478814	5	9.80957628	F(5, 752)	=	81.75
RSS	Residual	90.2382684	752	.119997697	Prob > F	=	0.0000
TSS	Total	139.28615	757	.183997556	R-squared	=	0.3521
					Adj R-squared	=	0.3478
					Root MSE	=	.34641

F统计量

P值

R<sup>2</sup>

Adjusted R<sup>2</sup>

回归系数

标准误

t统计量

P值

置信区间

被解释变量	lnw	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
解释变量	s	.102643	.0058488	17.55	0.000	.0911611	.114125
	expr	.0381189	.0063268	6.02	0.000	.0256986	.0505392
	tenure	.0356146	.0077424	4.60	0.000	.0204153	.0508138
	smsa	.1396666	.0280821	4.97	0.000	.0845379	.1947954
	rns	-.0840797	.0287973	-2.92	0.004	-.1406124	-.0275471
	_cons	4.103675	.085097	48.22	0.000	3.936619	4.270731

```
. esttab , se r2 b(4) star(* 0.1 ** 0.05 *** 0.01) nogap
```

	(1)
	lnw
s	0.1026*** (0.0062)
expr	0.0381*** (0.0066)
tenure	0.0356*** (0.0080)
smsa	0.1397*** (0.0281)
rns	-0.0841*** (0.0295)
_cons	4.1037*** (0.0877)
N	758
R-sq	0.352

Standard errors in parentheses  
\* p<0.1, \*\* p<0.05, \*\*\* p<0.01

```
. reg lnw s expr tenure smsa rns, robust
```

Linear regression

Number of obs = 758  
F(5, 752) = 84.05  
Prob > F = 0.0000  
R-squared = 0.3521  
Root MSE = .34641

	lnw	Coefficient	Robust std. err.	t	P> t	[95% conf. interval]	
s		.102643	.0062099	16.53	0.000	.0904523	.1148338
expr		.0381189	.0066144	5.76	0.000	.025134	.0511038
tenure		.0356146	.0079988	4.45	0.000	.0199118	.0513173
smsa		.1396666	.028056	4.98	0.000	.0845893	.194744
rns		-.0840797	.029533	-2.85	0.005	-.1420566	-.0261029
_cons		4.103675	.0876665	46.81	0.000	3.931575	4.275775

谢谢！