

# 第9章 二值选择模型

# 二值选择模型


- 如果被解释变量 $y$ 离散，称为“离散选择模型” (discrete choice model)或“定性反应模型” (qualitative response model)。
- 最常见的离散选择模型是二值选择行为(binary choices)。
- 比如：考研或不考研；就业或待业；买房或不买房；买保险或不买保险；贷款申请被批准或拒绝；出国或不出国；回国或不回国；战争或和平；生或死。

- 假设个体只有两种选择, 比如 $y = 1$ (考研)或 $y = 0$ (不考研)。
- 最简单的建模方法为**线性概率模型**(Linear Probability Model, LPM):

$$y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_K x_{iK} + \varepsilon_i = \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i \quad (i = 1, \cdots, n)$$

- 其中, 解释变量 $\mathbf{x}_i \equiv (x_{i1} \ x_{i2} \ \cdots \ x_{iK})'$ , 而参数 $\boldsymbol{\beta} \equiv (\beta_1 \ \beta_2 \ \beta_K)'$
- LPM 的优点是, 计算方便, 容易得到边际效应(即回归系数)。

- LPM 的缺点是，虽然 $y$ 的取值非 0 即 1，但根据线性概率模型所作的预测值却可能出现 $\hat{y} > 1$ 或 $\hat{y} < 0$ 的不现实情形。



- 为使  $y$  的预测值介于  $[0,1]$  之间, 在给定  $x$  的情况下, 考虑  $y$  的两点分布概率:

$$\begin{cases} P(y = 1 | \mathbf{x}) = F(\mathbf{x}, \boldsymbol{\beta}) \\ P(y = 0 | \mathbf{x}) = 1 - F(\mathbf{x}, \boldsymbol{\beta}) \end{cases}$$

- 函数  $F(\mathbf{x}, \boldsymbol{\beta})$  称为“连接函数”(link function), 因为它将  $x$  与  $y$  连接起来。
- $y$  的取值要么为 0, 要么为 1, 故  $y$  肯定服从两点分布。
- 连接函数的选择具有一定灵活性。
- 通过选择合适的连接函数  $F(\mathbf{x}, \boldsymbol{\beta})$  (比如, 某随机变量的累积分布函数), 可保证  $0 \leq \hat{y} \leq 1$ , 并将  $\hat{y}$  理解为“ $y = 1$ ”发生的概率, 因为
$$E(y|\mathbf{x}) = 1 \cdot P(y = 1|\mathbf{x}) + 0 \cdot P(y = 0|\mathbf{x}) = P(y = 1|\mathbf{x})$$

- 如果 $F(\mathbf{x}, \boldsymbol{\beta})$ 为标准正态的累计分布函数, 则

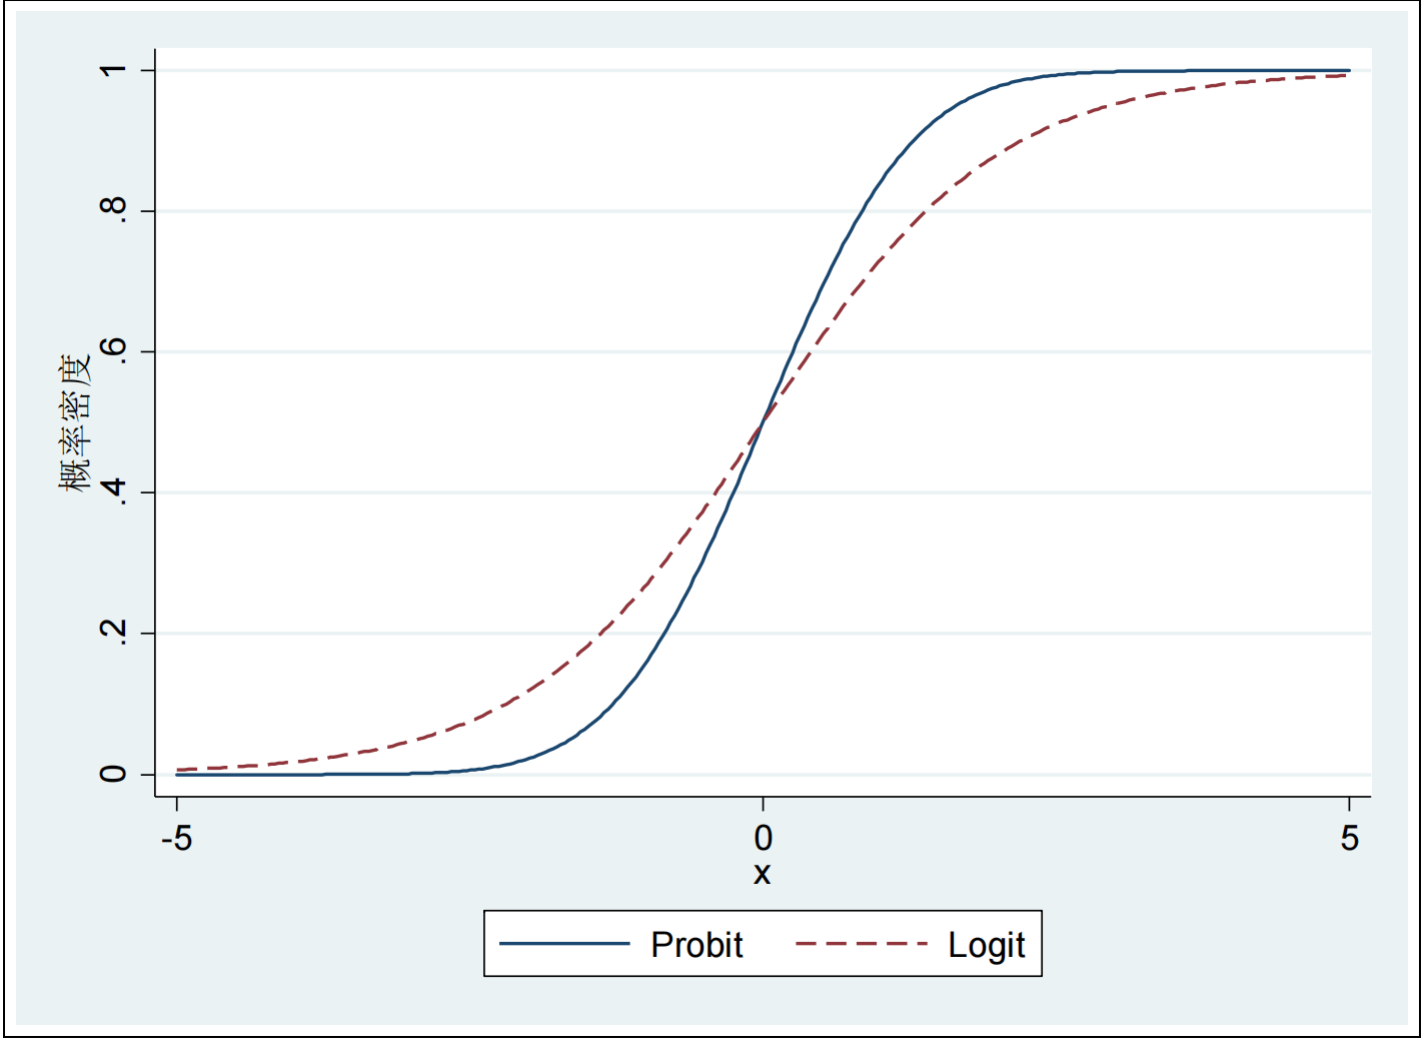
$$P(y = 1 \mid \mathbf{x}) = F(\mathbf{x}, \boldsymbol{\beta}) = \Phi(\mathbf{x}'\boldsymbol{\beta}) \equiv \int_{-\infty}^{\mathbf{x}'\boldsymbol{\beta}} \phi(t) dt$$

- $\phi(\cdot)$ 与 $\Phi(\cdot)$ 分别为标准正态的密度与累积分布函数; 此模型称为“Probit”。
- 如果 $F(\mathbf{x}, \boldsymbol{\beta})$ 为“逻辑分布”(logistic distribution)的累积分布函数, 则

$$P(y = 1 \mid \mathbf{x}) = F(\mathbf{x}, \boldsymbol{\beta}) = \Lambda(\mathbf{x}'\boldsymbol{\beta}) \equiv \frac{\exp(\mathbf{x}'\boldsymbol{\beta})}{1 + \exp(\mathbf{x}'\boldsymbol{\beta})}$$

- 其中, 函数 $\Lambda(\cdot)$ 的定义为 $\Lambda(z) \equiv \frac{\exp(z)}{1 + \exp(z)}$ ; 此模型称为“Logit”。

- 逻辑分布的密度函数关于原点对称，期望为 0，方差为  $\pi^2/3$ （大于标准正态的方差），具有厚尾(fat tails)。
- Probit 与 Logit 都很常用，二者的估计结果(比如边际效应)通常很接近。
- Logit 模型的优势在于：
  - （1）逻辑分布的累积分布函数有解析表达式(标准正态没有)，故计算 Logit 更为方便；
  - （2）Logit 的回归系数更易解释其经济意义。





# 最大似然估计的原理

- Probit 与 Logit 模型本质上都是非线性模型，无法通过变量转换变为线性模型。
- 对于非线性模型，常使用最大似然估计法(Maximum Likelihood Estimation, MLE 或 ML)。

- 假设随机变量 $y$ 的概率密度函数 $f(y; \theta)$ , 其中 $\theta$ 为未知参数。
- 为估计 $\theta$ , 从 $y$ 的总体中抽取样本容量为 $n$ 的随机样本 $\{y_1, \dots, y_n\}$ 。
- 假设 $\{y_1, \dots, y_n\}$ 为iid, 样本数据的联合密度函数为

$$f(y_1; \theta) f(y_2; \theta) \cdots f(y_n; \theta) = \prod_{i=1}^n f(y_i; \theta)$$

- 其中,  $\prod_{i=1}^n$  表示连乘。
- 抽样之前,  $\{y_1, \dots, y_n\}$ 为随机向量。
- 抽样之后,  $\{y_1, \dots, y_n\}$ 有了特定的样本值。
- 可将样本的联合密度函数视为在给定 $\{y_1, \dots, y_n\}$ 情况下, 未知参数 $\theta$ 的函数。

- 定义 **似然函数**(likelihood function)为

$$L(\theta; y_1, \cdots, y_n) = \prod_{i=1}^n f(y_i; \theta)$$

- 似然函数与联合密度函数完全相等，只是 $\theta$ 与 $\{y_1, \cdots, y_n\}$ 的角色互换，即把 $\theta$ 作为自变量，视 $\{y_1, \cdots, y_n\}$ 为给定。
- 为运算方便，把似然函数取对数：

$$\ln L(\theta; y_1, \cdots, y_n) = \sum_{i=1}^n \ln f(y_i; \theta)$$

- 取对数是单调变换，不影响最大化的求解。

- MLE 的思想：给定样本取值后，该样本最可能来自参数 $\theta$ 为何值的总体。
- 寻找 $\hat{\theta}_{ML}$ ，使得观测到样本数据的可能性最大，即最大化对数似然函数(loglikelihood function)：

$$\max_{\theta} \ln L(\theta; y_1, \dots, y_n)$$

- 假设存在唯一内点解，一阶条件为


$$\frac{\partial \ln L(\theta; y_1, \dots, y_n)}{\partial \theta} = 0$$

- 求解一阶条件，可得最大似然估计量 $\hat{\theta}_{ML}$ 。

- **例** 假设 $y \sim N(\mu, \sigma^2)$ , 其中 $\sigma^2$ 已知, 得到样本容量为 1 的样本 $y_1 = 2$ , 求对 $\mu$ 的最大似然估计。根据正态分布的密度函数, 此样本的似然函数为

$$L(\mu) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{\frac{-(2-\mu)^2}{2\sigma^2}\right\}$$


- 似然函数在 $\hat{\mu} = 2$ 处取最大值



- 在一定的正则条件(regularity conditions)下, MLE 估计量具有良好的大样本性质, 可照常进行大样本统计推断。
- (1)  $\hat{\theta}_{ML}$  为一致估计, 即  $plim \hat{\theta}_{ML} = \theta$ 。
- (2)  $\hat{\theta}_{ML}$  服从渐近正态分布。
- (3) 在大样本下,  $\hat{\theta}_{ML}$  是最有效率的估计 (渐近方差最小)。

- 由于模型存在非线性，MLE 通常没有解析解，只能寻找“数值解” (numerical solution)。
- 一般使用“迭代法” (iteration) 进行数值求解。
- 常用的迭代法为“高斯-牛顿法” (Gauss-Newton method)。
- MLE 的一阶条件可归结为求非线性方程  $f(x) = 0$  的解。
- 假设  $f(x)$  的导数  $f'(x)$  处处存在。记该方程的解为  $x^*$ ，满足  $f(x^*) = 0$ 。





- 首先, 猜初始值 $x_0$ , 在点 $(x_0, f(x_0))$ 处作曲线 $f(x)$ 的切线, 记切线与横轴的交点为 $x_1$ 。
- 然后, 在点 $(x_1, f(x_1))$ 处再作切线, 记切线与横轴的交点为 $x_2$ 。

- 以此类推，不断迭代，可得序列 $\{x_0, x_1, x_2, x_3, \dots\}$ 。
- 一般情况下，该序列将收敛至 $x^*$ （给定一个精确度，收敛到精确度范围内即停止）。
- 高斯-牛顿法的收敛速度很快，是二次的。如本次迭代的误差为0.1，则下次迭代的误差约为 $0.1^2$ ，下下次迭代的误差约为 $0.1^4$ ，等等。
- 如果初始值 $x_0$ 选择不当，也可能出现迭代不收敛的情形。
- 使用牛顿法得到的可能只是“局部最大值” (local maximum)，而非“整体最大值” (global maximum)。

- MLE 很容易应用于多参数的情形。
- 假设随机变量 $y$ 的概率密度函数为 $f(y; \boldsymbol{\theta})$ , 其中 $\boldsymbol{\theta} = (\theta_1 \ \theta_2)'$ , 则对数似然函数为

$$\ln L(\boldsymbol{\theta}; y_1, \dots, y_n) = \sum_{i=1}^n \ln f(y_i; \boldsymbol{\theta})$$

一阶条件为

$$\begin{cases} \frac{\partial \ln L(\boldsymbol{\theta}; y_1, \dots, y_n)}{\partial \theta_1} = 0 \\ \frac{\partial \ln L(\boldsymbol{\theta}; y_1, \dots, y_n)}{\partial \theta_2} = 0 \end{cases}$$

- 求解此联立方程组, 可得最大似然估计量 $\hat{\theta}_{1,ML}$ 与 $\hat{\theta}_{2,ML}$ 。
- 高斯-牛顿法也适用于多元函数 $f(\mathbf{x}) = 0$ 的情形, 只要在上述迭代的过程中, 将切线替换为(超)切平面即可。

# 二值选择模型的 MLE 估计

- 以 Logit 为例，将 MLE 应用于二值选择模型。
- 对于样本数据  $\{\mathbf{x}_i, y_i\}_{i=1}^n$ ，根据逻辑分布的累计分布函数，第  $i$  个观测数据的概率密度为

$$f(y_i | \mathbf{x}_i, \boldsymbol{\beta}) = \begin{cases} \Lambda(\mathbf{x}_i' \boldsymbol{\beta}), & \text{若 } y_i = 1 \\ 1 - \Lambda(\mathbf{x}_i' \boldsymbol{\beta}), & \text{若 } y_i = 0 \end{cases}$$

- 其中， $\Lambda(z) \equiv \frac{\exp(z)}{1 + \exp(z)}$  为逻辑分布的累计分布函数。

- 上式可写为

$$f(y_i | \mathbf{x}_i, \boldsymbol{\beta}) = [\Lambda(\mathbf{x}_i' \boldsymbol{\beta})]^{y_i} [1 - \Lambda(\mathbf{x}_i' \boldsymbol{\beta})]^{1-y_i}$$

- 取对数可得

$$\ln f(y_i | \mathbf{x}_i, \boldsymbol{\beta}) = y_i \ln[\Lambda(\mathbf{x}_i' \boldsymbol{\beta})] + (1 - y_i) \ln[1 - \Lambda(\mathbf{x}_i' \boldsymbol{\beta})]$$

- 假设样本中的个体相互独立，整个样本的对数似然函数为

$$\ln L(\boldsymbol{\beta} | \mathbf{y}, \mathbf{x}) = \sum_{i=1}^n y_i \ln[\Lambda(\mathbf{x}_i' \boldsymbol{\beta})] + \sum_{i=1}^n (1 - y_i) \ln[1 - \Lambda(\mathbf{x}_i' \boldsymbol{\beta})]$$

- 把对数似然函数对 $\boldsymbol{\beta}$ 求偏导，可得一阶条件。
- 满足一阶条件的估计量即为MLE估计量，记为 $\hat{\boldsymbol{\beta}}_{ML}$ 。

# 边际效应

- 对于线性模型，回归系数 $\beta_k$ 的经济意义就是变量 $x_k$ 对 $y$ 的边际效应(marginal effects)。
- 在非线性模型中，估计量 $\hat{\beta}_{ML}$ 一般并非边际效应。
- 以 Probit 为例， $P(y = 1|\mathbf{x}) = \Phi(\mathbf{x}'\boldsymbol{\beta}) \equiv \int_{-\infty}^{\mathbf{x}'\boldsymbol{\beta}} \phi(t)dt$
- 计算变量 $x_k$ 的边际效应（使用求倒数的chain rule）

$$\frac{\partial P(y = 1|\mathbf{x})}{\partial x_k} = \frac{\partial \Phi(\mathbf{x}'\boldsymbol{\beta})}{\partial x_k} = \frac{\partial \Phi(\mathbf{x}'\boldsymbol{\beta})}{\partial (\mathbf{x}'\boldsymbol{\beta})} \cdot \frac{\partial (\mathbf{x}'\boldsymbol{\beta})}{\partial x_k} = \phi(\mathbf{x}'\boldsymbol{\beta})\beta_k$$

- 由于 Probit 与 Logit 所用分布函数不同，其参数估计值不直接可比。需分别计算二者的边际效应，然后比较。
- 对于非线性模型，边际效应通常不是常数，随着向量 $x$ 而变。
- 非线性模型常用的边际效应概念：
  - (1) 平均边际效应 (average marginal effect)：分别计算在每个样本观测值上的边际效应，然后进行简单算术平均。
  - (2) 样本均值处的边际效应 (marginal effect at mean)：计算在 $x = \bar{x}$ 处的边际效应。
  - (3) 在某代表值处的边际效应 (marginal effect at a representative value)：给定 $x^*$ ，计算 $x = x^*$ 处的边际效应。
- 以上三种边际效应的计算结果可能有较大差异。

- 传统上，常计算样本均值处传统上，常计算样本均值处 $x = \bar{x}$ 的边际效应，因为计算方便。
- 但在非线性模型中，样本均值处的个体行为并不等于样本中个体的平均行为(average behavior of individuals differs from behavior of the average individual)。
- 对于政策分析而言，使用平均边际效应(Stata 的默认方法)，或在某代表值处的边际效应通常更有意义。



# 回归系数的经济意义

- $\hat{\beta}_{ML}$  并非边际效应，它究竟有什么含义？
- 对于 Logit 模型，记事件发生的概率为  $p \equiv P(y = 1|\mathbf{x})$ ，则事件不发生的概率为  $1 - p \equiv P(y = 0|\mathbf{x})$ 。
- 由于  $p = \Lambda(\mathbf{x}'\boldsymbol{\beta}) = \frac{\exp(\mathbf{x}'\boldsymbol{\beta})}{1 + \exp(\mathbf{x}'\boldsymbol{\beta})}$ ， $1 - p = \frac{1}{1 + \exp(\mathbf{x}'\boldsymbol{\beta})}$ ，故事件发生与不发生的几率为

$$\frac{p}{1 - p} = \exp(\mathbf{x}'\boldsymbol{\beta})$$

- $\frac{p}{1-p}$  称为 “几率” (odds) 或 “相对风险” (relative risk)。

- **例** 在检验药物疗效的随机实验中, “ $y = 1$ ”表示“生”, “ $y = 0$ ”表示“死”。如几率为 2, 意味着存活概率是死亡概率的两倍。

- 对方程两边取对数

$$\ln\left(\frac{p}{1-p}\right) = \mathbf{x}'\boldsymbol{\beta} = \beta_1 x_1 + \cdots + \beta_K x_K$$

- $\ln(\frac{p}{1-p})$ 称为 “对数几率” (log-odds)。
- 回归系数 $\hat{\beta}_j$ 表示, 变量 $x_j$ 增加一个微小量引起对数几率的边际变化。
- 取对数意味着百分比的变化, 故可把 $\hat{\beta}_j$ 视为半弹性(semi-elasticity), 即 $x_j$ 增加一单位引起几率比 $(\frac{p}{1-p})$ 的变化百分比。

- **例**  $\hat{\beta}_j = 0.12$ , 意味着 $x_j$ 增加一单位引起几率增加 12%。
- 如 $x_j$ 为离散变量(比如, 性别、子女数), 可使用另一解释法。
- 假设 $x_j$ 增加一单位, 从 $x_j$ 变为 $x_j+1$ , 记事件发生概率 $p$ 的新值为 $p^*$ , 则新几率与原几率的比率(即几率比, odds ratio)为

$$\frac{\frac{p^*}{1-p^*}}{\frac{p}{1-p}} = \frac{\exp[\beta_1 + \beta_2 x_2 + \cdots + \beta_j (x_j + 1) + \cdots + \beta_K x_K]}{\exp(\beta_1 + \beta_2 x_2 + \cdots + \beta_j x_j + \cdots + \beta_K x_K)} = \exp(\beta_j)$$

- $\exp(\hat{\beta}_j)$ 表示变量 $x_j$ 增加一单位引起几率的变化倍数。
- Stata称 $\exp(\hat{\beta}_j)$ 为几率比(odds ratio)。

- 例  $\hat{\beta}_j = 0.12$  , 则  $\exp(\hat{\beta}_j) = e^{0.12} = 1.13$  , 故当  $x_j$  增加一单位时, 新几率是原几率的 1.13 倍, 或增加 13% , 因为  $\exp(\hat{\beta}_j) - 1 = 1.13 - 1 = 0.13$ 。
- 如果  $\hat{\beta}_j$  较小, 则  $\exp(\hat{\beta}_j) - 1 \approx \hat{\beta}_j$  (将  $\exp(\hat{\beta}_j)$  泰勒展开) , 以上两种方法基本等价。
- 对于Probit模型, 无法对其系数  $\hat{\beta}_{ML}$  进行类似解释。

# 拟合优度

- 不存在平方和分解公式，无法计算 $R^2$ 。
- Stata 仍汇报“准 $R^2$ ”或“伪 $R^2$ ”(Pseudo  $R^2$ )，由 McFadden (1974)提出，定义为


$$\text{准}R^2 \equiv \frac{\ln L_0 - \ln L_1}{\ln L_0}$$

- $\ln L_1$ 为原模型的对数似然函数的最大值
- $\ln L_0$ 为以常数项为唯一解释变量的对数似然函数之最大值。
- 由于 $y$ 为两点分布，似然函数的最大可能值为 1(取值概率为 1)，故对数似然函数的最大可能值为 0，记为 $\ln L_{max}$ 。

- 由于  $\ln L_{max} = 0$  , 可将“准 $R^2$ ”写为

$$\text{准}R^2 \equiv \frac{\ln L_1 - \ln L_0}{\ln L_{max} - \ln L_0}$$

- 显然,  $0 \geq \ln L_1 \geq \ln L_0$  , 而  $0 \leq \text{准}R^2 \leq 1$  。
- 分子为对数似然函数的实际增加值 ( $\ln L_1 - \ln L_0$ ) ; 分母为对数似然函数的最大可能增加值 ( $\ln L_{max} - \ln L_0$ ) 。



- 判断拟合优度的另一方法是计算“正确预测的百分比” (percent correctly predicted)。
- 如发生概率的预测值  $\hat{y} \geq 0.5$ ，则认为其预测值  $y = 1$ 。
- 反之，则认为其预测  $y = 0$ 。
- 将预测值与实际值(样本数据)进行比较，可计算正确预测的百分比。

# 准最大似然估计

- 使用 MLE 的前提是对总体的分布函数作具体的假定。
- Probit 与 Logit 模型分别假设 $y$ 的两点分布概率为标准正态或逻辑分布的累积分布函数。
- 此分布函数的设定可能不正确，即存在“设定误差” (specification error)。
- **定义** 使用不正确的分布函数所得到的最大似然估计量，称为“准最大似然估计” (Quasi MLE, 简记 QMLE)或“伪最大似然估计” (Pseudo MLE)。
- 准最大似然估计是否一定不一致？不一定！



- **例** 假设线性模型的扰动项服从正态分布，则 MLE 估计量与 OLS 估计量完全相同，而 OLS 估计量的一致性并不依赖于关于分布函数的具体假设。
- 关于 QMLE 估计量的标准误，可分两种情况考虑。
- (1) 如果 QMLE 为一致估计量，由于可能存在对分布函数的设定误差，应使用稳健标准误(robust standard errors)，即相对于模型设定稳健的标准误。
- 此稳健标准误与异方差稳健的标准误是一致的，因为扰动项方差是否相同也是一种模型设定。

- (2) 如 QMLE 估计量不一致, 即使采用稳健标准误也无济于事。
- QMLE 估计量  $\hat{\beta}_{QML} \xrightarrow{p} \beta^* \neq \beta$ , 应首先担心估计量的一致性。
- 稳健标准误只是一致地估计了一个不一致估计量的方差(a consistent estimator of the variance of an inconsistent estimator)。
- 对于二值选择模型(Probit 或 Logit), 只要条件期望函数  $E(y|\mathbf{x}) = F(\mathbf{x}, \beta)$  设定正确, 则MLE估计就一致。
- 由于两点分布的特殊性, 在 iid 的情况下, 只要  $E(y|\mathbf{x}) = F(\mathbf{x}, \beta)$  成立, 稳健标准误就等于普通标准误。

- 如果认为模型设定正确，就不必使用稳健标准误(使用稳健标准误也没错)。
- 如果模型设定不正确（即 $E(y|x) \neq F(x, \beta)$ ），则Probit与Logit模型不能得到对系数 $\beta$ 的一致估计，使用稳健标准误就没有太大意义；首先应解决参数估计的一致性问题。
- 总之，对于二值选择模型，使用普通标准误或稳健标准误都可。

# 三类渐近等价的大样本检验

- 在计量中，常使用三类在大样本下渐近等价的统计检验。

- 考虑线性回归模型：

$$y_i = \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_K x_K + \varepsilon_i = \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i \quad (i = 1, \cdots, n)$$

- 其中，解释变量  $\mathbf{x} \equiv (x_1 \ x_2 \ \cdots \ x_K)'$ ，参数  $\boldsymbol{\beta} \equiv (\beta_1 \ \beta_2 \ \cdots \ \beta_K)'$

- 检验以下原假设：

$$H_0: \boldsymbol{\beta} = \boldsymbol{\beta}_0$$

其中， $\boldsymbol{\beta}_0$  已知，共有  $K$  个约束。

## (1) 沃尔德检验(Wald Test)


- 沃尔德检验考察 $\beta$ 的无约束估计量 $\hat{\beta}$ （未施加 $H_0$ 约束的估计量）与 $\beta_0$ 的距离。
- 基本思想：如果 $H_0$ 正确，则 $(\hat{\beta} - \beta_0)$ 不应该很大。
- 由于 $(\hat{\beta} - \beta_0)$ 为多维向量，使用二次型：

$$W \equiv (\hat{\beta} - \beta_0)' [\text{Var}(\hat{\beta})]^{-1} (\hat{\beta} - \beta_0) \xrightarrow{d} \chi^2(K)$$

- 其中K为约束条件的个数。
- 单一系数t 检验（大样本下使用标准正态进行检验）、联合线性假设的F 检验（大样本下可使用 $\chi^2$  分布进行检验）都是Wald 检验。

## (2) 似然比检验(Likelihood Ratio Test, 简记LR)

- 似然比检验比较无约束估计量 $\hat{\beta}$  (不施加任何约束) 与有约束估计量 $\hat{\beta}^*$  (施加 $H_0: \beta = \beta_0$ 的约束) 的差别。
- 无约束的似然函数最大值 $\ln L(\hat{\beta})$ 比有约束的似然函数最大值 $\ln L(\hat{\beta}^*)$ 更大, 因为在无约束条件下的参数空间 $\theta$ 比有约束条件下(即 $H_0$ 成立时)参数的取值范围更大。
- 基本思想: 如果 $H_0$ 正确, 则 $[\ln L(\hat{\beta}) - \ln L(\hat{\beta}^*)]$ 不应该很大。
- 在此例中, 有约束的估计量 $\hat{\beta}^* = \beta_0$ 。



- LR统计量为

$$LR \equiv -2 \ln \left[ \frac{L(\hat{\beta}^*)}{L(\hat{\beta})} \right] = 2 \left[ \ln L(\hat{\beta}) - \ln L(\hat{\beta}^*) \right] \xrightarrow{d} \chi^2(K)$$

- 在大样本下，LR统计量也服从渐近 $\chi^2(K)$ 分布。
- F统计量的表达式  $F = \frac{(SSR^* - SSR)/(K-1)}{SSR/(n-K)}$ ，即依据似然比原理而设计。
- 在进行 Probit 或 Logit 回归时，Stata 会汇报一个似然比统计量，检验除常数项外所有参数的联合显著性。

- (3) **拉格朗日乘子检验**(Lagrange Multiplier Test, 简记LM )
- Wald 检验只考察无约束估计量 $\hat{\beta}$ 。
- LR检验同时考察无约束估计量 $\hat{\beta}$ 与有约束估计量 $\hat{\beta}^*$ 。
- LM 检验则只考察有约束估计量 $\hat{\beta}^*$ 。
- 有约束条件的对数似然函数最大化问题：

$$\max_{\tilde{\beta}} \ln L(\tilde{\beta})$$

$$s.t. \tilde{\beta} = \beta_0$$

- $\tilde{\beta}$ 为在最大化过程中假想的参数 $\beta$ 取值(hypothetical value)。



- 对于约束极值问题，引入拉格朗日乘子函数：

$$\max_{\tilde{\beta}, \lambda} \ln L(\tilde{\beta}) - \lambda'(\tilde{\beta} - \beta_0)$$

- $\lambda$ 为拉格朗日乘子向量(Lagrange Multiplier)，其经济含义为约束条件(比如资源约束)的影子价格(shadow price)。
- 如果 $\hat{\lambda} = 0$ ，约束条件完全不起作用(可无偿获取任意数量的资源)。
- 根据一阶条件（对 $\tilde{\beta}$ 求导）可知，最优的拉格朗日乘子向量 $\hat{\lambda}$ 等于对数似然函数在约束估计量 $\hat{\beta}^*$ 处的一阶偏导数（切线的斜率）。

$$\hat{\lambda} = \frac{\partial \ln L(\hat{\beta}^*)}{\partial \tilde{\beta}} \equiv \begin{pmatrix} \frac{\partial \ln L(\hat{\beta}^*)}{\partial \tilde{\beta}_1} \\ \vdots \\ \frac{\partial \ln L(\hat{\beta}^*)}{\partial \tilde{\beta}_K} \end{pmatrix}$$


- 如  $\hat{\lambda} \approx \mathbf{0}$  , 说明约束条件不 “紧” (tight) 或不是 “硬约束” (binding constraint), 加上约束条件不会使似然函数的最大值下降很多, 即原假设  $H_0$  很可能成立。(基本思想)
- 如果原假设  $H_0$  成立, 则  $(\hat{\lambda} - \mathbf{0})$  的绝对值不应很大。
- 以二次型来度量此距离, 可得LM 统计量:

$$LM \equiv \hat{\lambda}' [\text{Var}(\hat{\lambda})]^{-1} \hat{\lambda} \xrightarrow{d} \chi^2(K)$$

- 其中,  $\text{Var}(\hat{\lambda})$  为  $\hat{\lambda}$  的协方差矩阵。
- 由于  $\hat{\lambda} = \frac{\partial \ln L(\tilde{\beta})}{\partial \tilde{\beta}}$  称为 “得分函数” (score function) 或 “得分向量” (score vector), 此检验也称 “得分检验” (score test)。

- 另一直观理解是，由于在无约束估计量 $\hat{\beta}$ 处， $\frac{\partial \ln L(\hat{\beta})}{\partial \tilde{\beta}} = \mathbf{0}$  (MLE 的一阶条件)，故如原假设 $H_0$ 成立，则在约束估计量 $\hat{\beta}^*$ 处， $\frac{\partial \ln L(\hat{\beta}^*)}{\partial \tilde{\beta}} \approx \mathbf{0}$ ，而LM 统计量反映的就是此接近程度。
- 对异方差与自相关所进行的 $nR^2$ 形式的检验都来自LM 检验的推导。

- 这三类检验在大样本下渐近等价，从不同侧面考察同一事物。



- 究竟采取哪种检验常取决于“无约束估计”与“有约束估计”哪种更方便。
- 如果无约束估计更方便，常使用 Wald 检验(比如，对线性回归系数的显著性检验)；
- 如果有约束估计更方便，常使用LM 检验(比如，对异方差、自相关的检验)；
- 如果二者都方便，可使用LR检验(比如，对非线性回归方程的显著性检验)。

# 其他离散选择模型

- (1) 多值选择(multiple choices): 比如, 对交通方式的选择(步行、骑车、自驾车、打的、地铁), 对不同职业的选择, 对手机品牌的选择。
- (2) 计数数据(count data): 有时被解释变量只能取非负整数。比如, 企业在某段时间内获得的专利数; 某人在一定时间内去医院看病的次数; 某省在一年内发生煤矿事故的次数。
- (3) 排序数据(ordered data): 有些离散数据有着天然的排序。比如, 公司债券的评级(AAA, AA, A, B, C 级), 对“春节联欢晚会”的满意度(很满意、满意、不满意、很不满意)。

- 对于以上离散数据，一般也不宜直接进行 OLS 回归，主要估计方法仍为 MLE。
- 由于离散选择模型主要用于微观经济学的实证研究中，故是“微观计量经济学” (Microeconometrics)的重要组成部分。
- 除了离散数据外，微观计量经济学还关注的另一类数据类型为“受限被解释变量” (limited dependent variable)，即被解释变量的取值范围受到限制(包括断尾回归、归并回归与样本选择模型等)。